Robustní strojové učení a adversariální vzorky

Pavel Jakš

Matematická informatika, FJFI ČVUT v Praze

21. srpna 2022

Obsah

Neuronová síť

- Odpovídá jí zobrazení $F_\theta : \mathbb{R}^{n_1 \times \ldots \times n_k} \to \mathbb{R}^{m_1 \times \ldots \times m_l}$
  - θ jsou *parametry neuronové sítě*
  - Jedná se o zobrazení složené z tzv. vrstev [1]
- Hledání vhodných parametrů θ pro neuronovou síť
  - Převedení na optimalizaci vhodné ztrátové funkce

Častá volba sestává z dílčích ztrát

$$J(\theta) = \frac{1}{N} \sum_{i=1}^{N} L\left(F_\theta(x^{(i)}), y^{(i)}\right)$$

- Tento přístup vyžaduje existenci *trénovací datové sady*
  - Uspořádaná dvojice
    $\mathbb{T} = \left(\left\{x^{(i)} | i \in \{1, \ldots, N\}\right\}, \left\{y^{(i)} | i \in \{1, \ldots, N\}\right\}\right)$
- Cílem je $F_\theta(x^{(i)}) = y^{(i)} \quad \forall i \in \{1, \ldots, N\}$

Adversariální vzorek

- Szegedy a spol. objevili zvláštní chování klasifikačních sítí [2]

Existence adversariálních vzorků

$$\exists x, y : \exists \Delta x, \|\Delta x\| \leq \kappa :$$
$$C(F(x)) = C(y) \wedge C(F(x + \Delta x)) \neq C(y)$$

- Označme $\tilde{x} = x + \Delta x$

Metody generování adversariálních vzorků

- FGSM
  - $\tilde{x} = x + \kappa \cdot \text{sign}\left(\nabla_x L(F(x), y)\right)$
- I-FGSM
  - $\tilde{x}_0 = x$
  - $\tilde{x}_{n+1} = \text{Clip}_x^{\kappa}\{\tilde{x}_n + \gamma \cdot \text{sign}(\nabla_x L(F_\theta(x), y))\}$
- PGD
- Cílená optimalizační metoda
  - $\tilde{x} = \text{argmin}_{\hat{x}}\left(\|\hat{x} - x\| + \lambda \cdot L(F_\theta(\hat{x}), \tilde{y})\right)$
- CW
  - $\tilde{x} = \text{argmin}_{\hat{x}}\left(\|\hat{x} - x\| - \lambda \cdot L(F_\theta(\hat{x}), y)\right)$

Příklady vzorků vygenerovaných metodami generování adversariálních vzorků

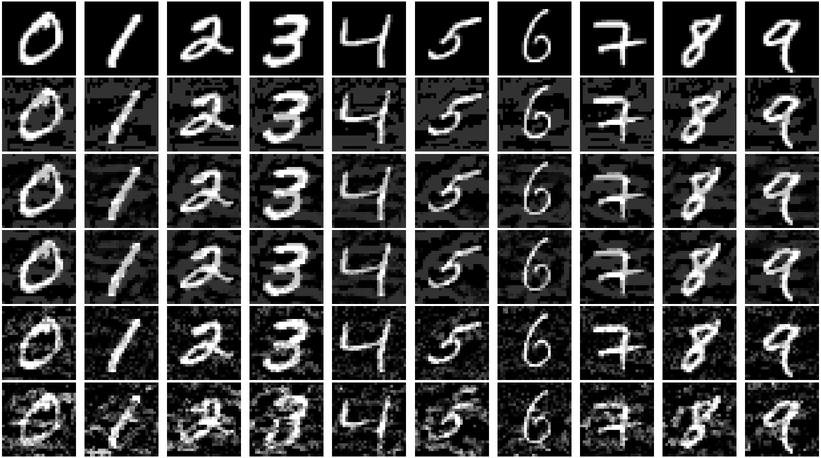

Obrázek: Vzorky generované různými metodami hledání adversariálních vzorků

Robustní učení

- Snaha o *robustnost* klasifikátorů proti adversariálním útokům

Obecná formulace problému

$$\theta = \operatorname{argmin}_\theta \frac{1}{N} \sum_{i=1}^{N} \max_{\tilde{x} \in B(x^{(i)}, \kappa)} L\left(F_\theta(\tilde{x}), y^{(i)}\right)$$

Úspěšnost metod generování adversariálních vzorků

Metoda	Úspěšnost	Robustní úspěšnost
FGSM	40.4 %	5.7 %
I-FGSM	78.4 %	7.0 %
PGD	78.8 %	6.9 %
Cílená optimalizační metoda	100 %	100 %
CW	99.7 %	100 %

Tabulka: Úspěšnost metod generování adversariálních vzorků

Příklady vzorků vygenerovaných metodami generování adversariálních vzorků proti robustně naučené síti

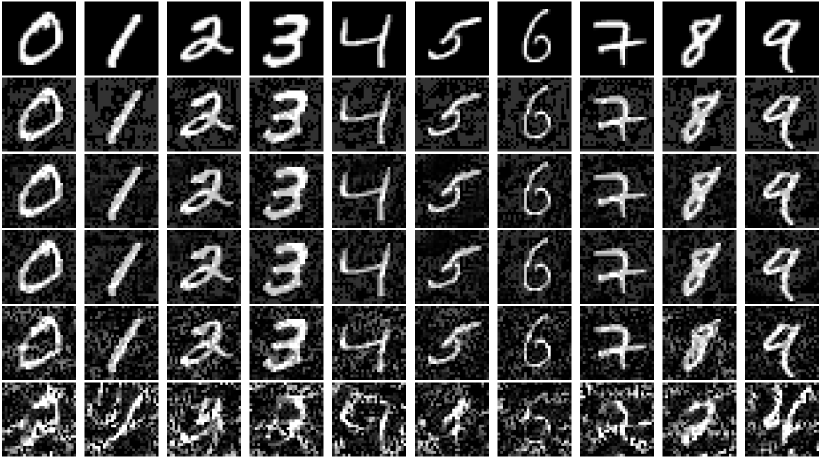

Obrázek: Vzorky generované metodami hledání adversariálních vzorků proti robustně naučené síti

Závěr

- Metody strojového učení skrývají úskalí
- Lze snadno zneužít adversariálních vzorků
- Proti takovým útokům se však lze bránit

Literatura

- I. Goodfellow, Y. Bengio, A. Courville, *Deep Learning*. MIT Press, 2016.
- C. Szegedy, W. Zaremba, I. Sutskever, J. Bruna, D. Erhan, I. Goodfellow, R. Fergus, *Intriguing properties of neural networks*. arXiv, 2014.

Hledání λ pomocí bisekce

- Připomenutí: $\tilde{x} = \operatorname{argmin}_{\hat{x}} \left(\|\hat{x} - x\| - \lambda \cdot L(F_\theta(\hat{x}), y) \right)$
- Cíl: Nalézt λ, pro které je řešení problému nesprávně klasifikováno a zároveň $\|\tilde{x} - x\|$ je co nejmenší
- Definuji pomocnou funkci $g : (0, +\infty) \to \{-1, 1\}$
  - $g(\lambda) = 1$, pokud $\tilde{x}$ pro ono λ je nesprávně klasifikováno
  - $g(\lambda) = -1$, pokud $\tilde{x}$ pro ono λ je správně klasifikováno

Hledání λ pomocí bisekce

1. Nalézt ν, pro které $g(\nu) = 1$
2. Nalézt μ, pro které $g(\mu) = -1$
3. Ozn. $\lambda = \mu + \frac{\nu - \mu}{2}$
   - Pro $g(\lambda) = 1$ provést $\nu \leftarrow \lambda$
   - Pro $g(\lambda) = -1$ provést $\mu \leftarrow \lambda$
4. Opakovat až $\nu - \mu < \varepsilon$
5. Vrátit ν

Bisekce a konvergence

- Věta o konvergenci bisekce požaduje spojitost funkce, jejíž kořeny se hledají
- To ovšem g není
- Nicméně posloupnost čísel ν je Cauchyovská v $\mathbb{R}$
- Čili, lze-li provést každý krok algoritmu, pak metoda konverguje

Cílené FGSM

- Předpis cílené FGSM: $\tilde{x} = x - \kappa \cdot \operatorname{sign}\left(\nabla_x L(F(x), \tilde{y})\right)$

Počet iterací tréningu neuronové sítě

- Volba probíhala s přihlédnutím k následujícím faktorům:
  - Dostatečný počet vzorků, které síť během trénování potká
    - $5000 \cdot 30 = 150000 > 60000$
  - Úspěšnost sítě na testovací datové sadě
  - CPU čas (trénoval jsem na CPU)

Porovnávání úspěšnosti útoku

- Čistě porovnání procentuální úspěšnosti útoku nezohledňuje blízkost adversariálního vzorku k benignímu
- Čili jako srovnání metod by byla lepší dvojice čísel, a to procentuální úspěšnost útoku a statistika norem perturbací (např. průměr)

Volba použité normy

- Blíže bude vzorek s euklidovskou normou perturbace menší než 0.5 oproti vzorku s maximovou normou perturbace menší než 0.5