

# České vysoké učení technické v Praze Fakulta jaderná a fyzikálně inženýrská



# Robustní strojové učení a adversariální vzorky Robust machine learning and adversarial examples

Bakalářská práce

Autor: Pavel Jakš

Vedoucí práce: Mgr. Lukáš Adam, Ph.D.

Akademický rok: 2021/2022





Poděkování: Chtěl bych zde poděkovat především svému školiteli - panu doktoru Adamovi - za pečlivo vstřícnost a odborné i lidské zázemí při vedení mé bakalářské práce.	ost, ochotu,			
<i>Čestné prohlášení:</i> Prohlašuji, že jsem tuto práci vypracoval samostatně a uvedl jsem všechnu použitou literaturu.				
V Praze dne 7. července 2022	Pavel Jakš			

Název práce:

#### Robustní strojové učení a adversariální vzorky

Autor: Pavel Jakš

Obor: Matematická informatika

Druh práce: Bakalářská práce

Vedoucí práce: Mgr. Lukáš Adam, Ph.D., Katedra počítačů, Fakulta elektrotechnická, České vysoké

učení technické v Praze, Karlovo náměstí 13, 121 35, Praha 2

Abstrakt: Abstrakt max. na 10 řádků. Abstrakt max. na 10 řádků.

Klíčová slova: klíčová slova (nebo výrazy) seřazená podle abecedy a oddělená čárkou

Title:

#### Robust machine learning and adversarial examples

Author: Pavel Jakš

Abstract: Max. 10 lines of English abstract text. Max. 10 lines of English abstract text.

Key words: keywords in alphabetical order separated by commas

#### **Obsah**

Ú۱	vod		11
1	Neu	ronové sítě	13
	1.1	Hluboká dopředná neuronová síť	13
	1.2	Konvoluční neuronové sítě	13
		1.2.1 Konvoluce	13
		1.2.2 Pooling	13
2	Učei	ní neuronové sítě	15
	2.1	Účelové funkce	15
		2.1.1 Střední kvadratická chyba	15
		2.1.2 Ztráta křížové entropie	15
	2.2	Algoritmus zpětného šíření chyby	15
	2.3	Algoritmy učení	15
		2.3.1 Gradientní sestup	15
		2.3.2 Stochastický gradientní sestup	15
		2.3.3 Adam	15
3	Adv	ersariální vzorky	17
	3.1	Metody generování adversariálních vzorků	17
		3.1.1 FGSM	17
		3.1.2 Iterativní FGSM	17
4	Rob	ustní učení neuronové sítě	19
Zź	ivěr		21

# Úvod

Text úvodu....

### Neuronové sítě

- 1.1 Hluboká dopředná neuronová síť
- 1.2 Konvoluční neuronové sítě
- 1.2.1 Konvoluce
- 1.2.2 Pooling

#### Učení neuronové sítě

- 2.1 Účelové funkce
- 2.1.1 Střední kvadratická chyba
- 2.1.2 Ztráta křížové entropie
- 2.2 Algoritmus zpětného šíření chyby
- 2.3 Algoritmy učení
- 2.3.1 Gradientní sestup
- 2.3.2 Stochastický gradientní sestup
- 2.3.3 Adam

# Adversariální vzorky

- 3.1 Metody generování adversariálních vzorků
- 3.1.1 FGSM
- 3.1.2 Iterativní FGSM

# Robustní učení neuronové sítě

## Závěr

Text závěru....

#### Literatura

- [1] I. Goodfellow, Y. Bengio, A. Courville, Deep Learning. MIT Press, 2016.
- [2] I. Goodfellow, J. Shlens, C. Szegedy, *Explaining and Harnessing Adversarial Examples*. In 'International Conference on Learning Representations', ICLR 2015.
- [3] J. Nocedal, S. Wright, Numerical optimization. Springer Science & Business Media, 2006.